



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO SOCIOECONÔMICO
DEPARTAMENTO DE CIÊNCIAS CONTÁBEIS
CURSO DE CIÊNCIAS CONTÁBEIS

Vanclercio da Rocha Pontes

Título: O Potencial da Inteligência Artificial para a Gestão da Informação em
Contabilidade pelo Método Retrieval-Augmented Generation (RAG)

Florianópolis

2026

Vanclercio da Rocha Pontes

Título: O Potencial da Inteligência Artificial para a Gestão da Informação em Contabilidade pelo Método Retrieval-Augmented Generation (RAG)

Trabalho de Conclusão de Curso submetido ao curso de Ciências Contábeis do Centro Socioeconômico da Universidade Federal de Santa Catarina como requisito parcial para a obtenção do título de Bacharel em Ciências Contábeis.

Orientador: Prof. Dr. Valmir Emil Hoffmann

Florianópolis

2026

Ficha catalográfica gerada por meio de sistema automatizado gerenciado pela BU/UFSC.
Dados inseridos pelo próprio autor.

Pontes, Vanclercio da Rocha
O Potencial da Inteligência Artificial para a Gestão da
Informação em Contabilidade pelo Método Retrieval-Augmented
Generation (RAG) / Vanclercio da Rocha Pontes ;
orientador, Valmir Emil Hoffmann , 2026.
40 p.

Trabalho de Conclusão de Curso (graduação) -
Universidade Federal de Santa Catarina, Centro
Socioeconômico, Graduação em Ciências Contábeis,
Florianópolis, 2026.

Inclui referências.

1. Ciências Contábeis. 2. Inteligência Artificial. 3.
Gestão da Informação Contábil. 4. Geração Aumentada por
Recuperação. 5. Grandes Modelos de Linguagem. I. Hoffmann ,
Valmir Emil . II. Universidade Federal de Santa Catarina.
Graduação em Ciências Contábeis. III. Título.

Vanclercio da Rocha Pontes

Título: O Potencial da Inteligência Artificial para a Gestão da Informação em Contabilidade pelo Método Retrieval-Augmented Generation (RAG)

Este Trabalho de Conclusão de Curso foi julgado adequado para obtenção do título de Bacharel em Ciências Contábeis e aprovado em sua forma final pelo Curso de Ciências Contábeis.

Local Florianópolis, [dia] de [mês] de 2026.

Insira neste espaço
a assinatura

Coordenação do Curso

Banca examinadora

Insira neste espaço
a assinatura

Prof.(a) [nome do(a) professor(a)], Dr.(a)
Orientador(a)

Insira neste espaço
a assinatura

Prof.(a) [nome do(a) professor(a)], Dr.(a)
Instituição [nome da instituição]

Insira neste espaço
a assinatura

Prof.(a) [nome do(a) professor(a)], Dr.(a)
Instituição [nome da instituição]

Florianópolis, 2026

A meu Deus.

Aos meus pais.

Aos meus professores e amigos.

RESUMO

O presente trabalho de conclusão de curso aborda o uso da Tecnologia da Informação no desafio da Gestão da Informação (GI) no contexto contábil brasileiro, caracterizado pelo processamento de grandes volumes de dados e por uma complexa e dinâmica legislação. A necessidade de precisão e rastreabilidade eleva os custos de conformidade (*compliance*) e impõe limites aos métodos tradicionais de gerenciamento. Diante disso, o objetivo deste estudo é apresentar os benefícios e as limitações da Inteligência Artificial (IA) para otimizar o acesso e o processamento de bases de conhecimento específicas, por meio da técnica de Geração Aumentada por Recuperação (RAG). A metodologia seguiu uma abordagem aplicada e descritiva, materializada no desenvolvimento de um protótipo de *chatbot* funcional integrado ao modelo GPT-3.5 Turbo e ao banco de dados vetorial Pinecone. A base de dados proprietária foi composta por 2.543 tutoriais técnicos do sistema de gestão ERP Sispetro. A validação do sistema foi realizada por meio de uma autoavaliação sistemática com checagem documental utilizando 24 perguntas-teste divididas em consultas diretas, de síntese e armadilhas. Os resultados empíricos demonstraram excelente desempenho em consultas diretas (média de 4,00 em precisão semântica), mas revelaram limitações em perguntas-armadilha (25% de acerto), evidenciando gargalos como a competição semântica e alucinações por generalização. Conclui-se que a arquitetura RAG é uma ferramenta promissora para o suporte estratégico na contabilidade, desde que refinada por mecanismos de reordenação (*reranking*) e filtros de similaridade para garantir a segurança informacional.

Palavras-chave: Geração Aumentada por Recuperação (RAG); Inteligência Artificial; Gestão da Informação Contábil; Grandes Modelos de Linguagem (LLMs); Sispetro.

ABSTRACT

This undergraduate thesis addresses the use of Information Technology in the challenge of Information Management (IM) within the Brazilian accounting context, characterized by the processing of large volumes of data and a complex and dynamic legislation. The need for precision and traceability increases compliance costs and imposes limits on traditional management methods. Therefore, this study aims to present the benefits and limitations of Artificial Intelligence (AI) in optimizing access to and processing of specific knowledge bases, specifically through the Retrieval-Augmented Generation (RAG) technique. The methodology follows an applied and descriptive approach, materialized through the development of a functional chatbot prototype integrated with the GPT-3.5 Turbo model and the Pinecone vector database. The proprietary database comprised 2,543 technical tutorials from the Sispetro ERP management system. System validation was conducted through a systematic self-assessment with document checking, using 24 test questions divided into direct, synthesis, and trap queries. Empirical results demonstrated excellent performance in direct queries (mean of 4.00 in semantic precision) but revealed limitations in trap questions (25% accuracy), highlighting bottlenecks such as semantic competition and hallucination by generalization. This study concludes that the RAG architecture is a promising tool for strategic support in accounting, provided it is refined by re-ranking mechanisms and similarity thresholds to ensure information security.

Keywords: Retrieval-Augmented Generation (RAG); Artificial Intelligence; Accounting Information Management; Large Language Models (LLMs); Sispetro.

SUMÁRIO

1 INTRODUÇÃO	8
Objetivos	10
Justificativa.....	11
Estrutura do Trabalho	12
2 REFERENCIAL TEÓRICO.....	13
Gestão da Informação no Contexto Contábil.....	13
Inteligência Artificial e sua Aplicação na Contabilidade.....	15
Relação entre RAG e a Gestão da Informação Contábil	20
3 METODOLOGIA	23
3.1 Classificação da Pesquisa.....	23
3.2 Fonte e coleta dos dados	23
3.3 Desenvolvimento do Protótipo RAG.....	24
3.4 Procedimentos de validação	25
4 ANÁLISES dos RESULTADO.....	27
4.1 Descrição do Ambiente Operacional e Interface	27
4.2 Composição da Amostra de Validação	28
4.3 Resultados	29
4.4 Discussão dos Resultados.....	31
5 CONCLUSÕES, Limites e recomendações	34
5.1 Conclusões	34
5.2 Limitações.....	35
5.3 Recomendações para Trabalhos Futuros	36
REFERÊNCIAS.....	37
APÊNDICE A – Síntese das 24 perguntas-teste, classificação e notas de avaliação	40

1 INTRODUÇÃO

Nas últimas décadas, a produção e transmissão exponencial de informação, impulsionadas pela Tecnologia da Informação e da Comunicação (TIC), representa um desafio significativo para as organizações. De acordo com Barbosa (2020), esse aumento exponencial tem provocado grandes mudanças na estrutura e funcionamento das organizações, tornando a estruturação e o uso adequado de grandes volumes de dados um desafio real. Tais transformações e a necessidade de sistemas de informação eficazes salientam a importância da adoção de perspectivas explícitas de Gestão da Informação (GI) nas organizações.

Neste contexto, surgiram campos como a Gestão da Informação (GI), Barbosa (2020) e Castanha e Cazane (2024) afirmam que a GI emerge como área crucial no cenário atual das organizações, visando contribuir para o alcance dos objetivos organizacionais por meio da capacidade de coletar, organizar e disseminar informações relevantes e de transformá-las em conhecimento acionável, constituindo um ativo valioso para qualquer organização. Para a contabilidade no Brasil, esse desafio é ainda mais acentuado, pois os profissionais contábeis precisam processar e analisar grandes volumes de dados financeiros, além de navegar por um complexo e vasto conjunto de regulamentações, leis, normas e tutoriais técnicos que são particularmente extensos e de difícil interpretação, elevando os custos de conformidade organizacional (CABELLO; NAKAO, 2021).

Segundo Cabello e Nakao (2021), a complexidade tributária no país é notória, sendo o ICMS (Imposto sobre Circulação de Mercadorias e Serviços) caracterizado pela existência de 27 legislações tributárias distintas — uma para cada estado e o Distrito Federal. Essa complexidade é agravada pelo dinamismo das normas, sendo que, em 2012, foram observadas, em média, 20 alterações diárias na legislação do ICMS (CABELLO; NAKAO, 2021). Os autores afirmam que uma maior complexidade tributária eleva os custos de conformidade, exigindo que os contribuintes incorram em despesas adicionais para evitar sanções e garantir o cumprimento da lei.

Diante desse cenário de complexidade informacional e regulatória, evidencia-se a necessidade de soluções que otimizem o acesso e o processamento de grandes volumes de informações técnicas e normativas no ambiente contábil. Nos últimos anos, a Inteligência Artificial (IA) — definida como a ciência e engenharia de produzir sistemas inteligentes (XIMENES DE MELO et al., 2024) — deixou de ser uma

promessa futurista e tornou-se cada vez mais presente no cotidiano, no trabalho e nas organizações (SILVA; COSTA; PIMENTA, 2022).

Canton et al. (2024) e Hasan (2022) apontam que a IA vem sendo incorporada em diferentes setores, não apenas como automação de tarefas, mas como suporte estratégico para a gestão da informação e a tomada de decisões. No contexto brasileiro, observa-se também uma rápida expansão do uso da IA em áreas como saúde, educação, finanças e segurança pública (CNN BRASIL, 2025). Globalmente, a Inteligência Artificial tem sido aplicada de forma crescente em segmentos como o comércio, o setor financeiro e a contabilidade, otimizando vendas, personalizando serviços, automatizando tarefas e aprimorando a análise de dados para a tomada de decisão (SILVA; COSTA; PIMENTA, 2022). Esse cenário redefine os métodos tradicionais de gerenciamento de dados e transforma a maneira como as organizações lidam com a informação (CANTON et al., 2024).

Nesse sentido, o campo da Gestão da Informação (GI) já identifica a Inteligência Artificial como uma tendência emergente de pesquisa e aplicação. A exploração de recursos avançados de TI, como IA e Big Data, é considerada fundamental para o desenvolvimento dessa área. A contabilidade, por sua vez, enfrenta o desafio do Big Data, e a IA atua como motor para processar, interpretar e analisar grandes volumes de dados, gerando insights e otimizando processos (LEWIS et al., 2020; MOUSCHOUTZI, 2025).

A integração da IA na contabilidade vai além da automação de tarefas repetitivas: ela oferece um novo patamar de eficiência, permitindo a análise de grandes volumes de dados estruturados e não estruturados de forma ágil e precisa, resultando em decisões mais assertivas e auxiliando na definição de estratégias (XIMENES DE MELO et al., 2024; ARAUJO; CORNACCHIONE, 2024). Por meio de Large Language Model (Grande Modelo de Linguagem - LLM), essa tecnologia possibilita que sistemas computacionais compreendam, interpretem e gerem texto de forma contextualizada (BROWN et al., 2020).

No entanto, mesmo com o avanço dos Grandes Modelos de Linguagem (LLMs), surgem novos desafios. Lewis et al. (2020) destacam que, embora esses modelos incorporem grandes volumes de conhecimento em seus parâmetros — absorvidos durante o treinamento a partir de textos da internet e outras fontes — sua capacidade de acessar e manipular esse conhecimento de forma precisa ainda é limitada, gerando "alucinações": respostas fabricadas sem base em dados reais. Para

um contador, uma alucinação em relação a uma norma técnica ou cálculo de imposto não é apenas um erro, mas um risco sério que pode levar a penalidades e perdas financeiras. Os autores apontam que, em tarefas intensivas em conhecimento, o desempenho desses modelos puramente paramétricos fica aquém de arquiteturas mais específicas. Além disso, fornecer a proveniência (a origem auditável) para suas respostas e a dificuldade de atualizar seu conhecimento permanecem como problemas de pesquisa em aberto.

É neste ponto que a Retrieval-Augmented Generation (Geração Aumentada por Recuperação — RAG) se destaca. Diferentemente dos modelos de linguagem que dependem apenas de seu conhecimento interno, o RAG combina a capacidade generativa da IA com a recuperação de informações de uma base de dados externa, criando um sistema híbrido que oferece respostas mais precisas e contextualizadas (LEWIS et al., 2020). Segundo Lewis et. al. (2020), essa abordagem permite que a IA baseie suas respostas em fatos provenientes de fontes verificáveis. Além de reduzir as alucinações, o RAG permite o uso de bases de dados proprietárias, garantindo maior confiabilidade, e especificidade nas respostas - um fator crucial para a precisão exigida na contabilidade. A capacidade de trabalhar com os documentos internos e confidenciais de uma empresa, como tutoriais e manuais, sem comprometer a segurança das informações, é uma das maiores vantagens do RAG para o ambiente contábil. Essas características tornam o RAG uma técnica promissora para aplicação no contexto contábil.

Objetivos

O presente trabalho tem como objetivo apresentar os benefícios e limitações da Inteligência Artificial (IA) no processo de consulta às bases de conhecimento específicas. Para alcançar esse objetivo geral, foram traçados os seguintes objetivos específicos: 1º Coletar e organizar a base de conhecimento composta por tutoriais do sistema de gestão de postos de combustíveis Sispetro; 2º Desenvolver um protótipo de *chatbot* inteligente baseado em Grande Modelo de Linguagem (LLM) para facilitar a consulta às bases de conhecimento do Sispetro; e 3º Validar o desempenho do protótipo desenvolvido por meio de um instrumento estruturado de avaliação, identificando seus benefícios e limitações na recuperação e geração de respostas técnicas a partir da base de conhecimento.

Diante desse cenário e dos desafios impostos pela gestão da informação na contabilidade, o presente trabalho busca responder à seguinte questão de pesquisa: **Como a Inteligência Artificial pode otimizar a consulta a grandes volumes de dados textuais e melhorar o acesso à informação no contexto contábil, utilizando a técnica de Retrieval-Augmented Generation (RAG)?**

Justificativa

A relevância deste estudo é percebida em duas camadas: acadêmica e profissional. No âmbito acadêmico, estudos recentes demonstram que a aplicação da Inteligência Artificial na área contábil ainda é um campo incipiente, com grande potencial de desenvolvimento (XIMENES DE MELO et al., 2024; HASAN, 2022). Araujo e Cornacchione (2024) destacam que, embora existam reflexões sobre oportunidades, desafios e riscos do uso de IA na contabilidade gerencial, ainda há lacunas significativas na literatura. Ao propor a aplicação da técnica de Geração Aumentada por Recuperação (RAG) para a gestão da informação na contabilidade, este trabalho busca contribuir para o preenchimento dessa lacuna, oferecendo uma análise sobre essa abordagem emergente no contexto contábil brasileiro.

No âmbito profissional, a pesquisa se justifica pela necessidade de soluções que aprimorem o acesso à informação em ambientes contábeis organizacionais. O desenvolvimento de um protótipo funcional neste trabalho permitirá avaliar empiricamente como essa técnica pode ser aplicada em bases de conhecimento proprietárias, como tutoriais e manuais técnicos, contribuindo para a discussão sobre alternativas tecnológicas que possam apoiar a gestão da informação contábil.

Nota sobre o uso de Inteligência Artificial: No processo de elaboração deste trabalho, ferramentas de inteligência artificial foram utilizadas como recurso de apoio em atividades específicas: o modelo Gemini (Google) foi utilizado para revisão gramatical e estilística de trechos do texto, e o modelo Claude (Anthropic) para suporte na depuração do código-fonte do protótipo desenvolvido. A redação, a argumentação acadêmica, a análise e interpretação dos dados e todas as decisões científicas são de autoria exclusiva do pesquisador. Nenhuma seção deste trabalho foi gerada automaticamente por modelos de linguagem.

Estrutura do Trabalho

Este trabalho está dividido em 5 capítulos, além das referências e apêndice. O Capítulo 1 **Introdução**, apresenta e contextualiza o problema e os objetivos da pesquisa. O Capítulo 2 aborda a **Referencial Teórico**, discutindo os conceitos de Gestão da Informação, Inteligência Artificial e a técnica RAG. No Capítulo 3, a **Metodologia** de pesquisa é detalhada. O Capítulo 4 destina-se à apresentação e **Análise dos Resultados** do protótipo desenvolvido. Por fim, o Capítulo 5 traz as **Conclusões, Limites e Recomendações** do trabalho, com a síntese dos resultados e as sugestões para pesquisas futuras.

2 REFERENCIAL TEÓRICO

O referencial teórico apresentado neste capítulo abrange os conceitos fundamentais que alicerçam este trabalho, estabelecendo as bases para o desenvolvimento do protótipo de um *chatbot* RAG. O texto é estruturado de forma progressiva, iniciando com a contextualização da Gestão da Informação (GI) no ambiente contábil, onde a complexidade documental e a necessidade de precisão de dados exigem o uso de sistemas de apoio à decisão eficientes. Em seguida, é explorado o papel da Inteligência Artificial (IA) e do Processamento de Linguagem Natural (PLN) como ferramentas capazes de automatizar a análise e a interpretação de grandes volumes de dados não estruturados no setor. O ponto central deste capítulo se aprofunda no Método de Geração Aumentada por Recuperação (Retrieval-Augmented Generation — RAG), apresentando sua arquitetura híbrida e seu potencial para mitigar as limitações de “alucinação” de Grande Modelo de Linguagem (LLM) tradicional. Por fim, a seção final articula a relação entre o RAG e a Gestão da Informação Contábil, demonstrando como essa convergência tecnológica fortalece a capacidade analítica do profissional e oferece suporte estratégico, transparência e rastreabilidade na consulta a bases de conhecimento específicas, como tutoriais e regulamentações.

Gestão da Informação no Contexto Contábil

Segundo Barbosa (2020), a Gestão da Informação (GI) surge como uma iniciativa estratégica em resposta ao aumento exponencial da produção e transmissão de dados promovido pela Tecnologia da Informação e Comunicação (TIC). Em um contexto organizacional, a GI é essencial para apoiar o alcance dos objetivos institucionais, visto que as organizações podem ser compreendidas como sistemas de informação, comunicação e decisão. Ainda de acordo com Barbosa (2020), a GI compreende um conjunto de processos gerenciais voltados à criação, obtenção, armazenamento, distribuição e uso eficiente da informação. Essa gestão atua em três dimensões fundamentais: apoio ao processo decisório, construção de significados sobre o ambiente externo e promoção da aprendizagem organizacional.

A produção científica sobre GI demonstra conexões relevantes com áreas como Administração, Contabilidade e Negócios. Na área contábil, a GI assume papel

estratégico, uma vez que a Contabilidade tem por objetivo gerar informações financeiras, econômicas e patrimoniais úteis e confiáveis para a tomada de decisões. O Sistema de Informação Contábil (SIC) constitui o principal instrumento para esse propósito, sendo responsável por registrar, processar e fornecer dados relevantes aos diversos usuários (GARCIA et al., 2007; SILVA; COSTA; PIMENTA, 2022;). Dessa forma, o SIC proporciona agilidade, rastreabilidade e confiabilidade ao processo decisório.

Diante das transformações impulsionadas pela Tecnologia da Informação e Comunicação (TIC), as organizações precisam desenvolver estratégias de gestão da informação em níveis cada vez mais estratégicos. No contexto brasileiro, a complexidade da legislação tributária — marcada por diferentes regulações e alterações constantes — eleva os custos de conformidade e reforça a necessidade de sistemas capazes de organizar, atualizar e interpretar dados normativos em tempo real (CABELLO; NAKAO, 2021).

Diante do cenário de transformações impulsionadas pela TIC, as organizações necessitam desenvolver processos e estratégias de gerenciamento da informação em níveis estratégicos, destaca Barbosa (2020). Em particular, a complexidade da legislação tributária no Brasil, caracterizada por um grande volume e dinamismo de dispositivos legais, exige que as empresas incorram em custos de compliance, que são custos adicionais, como mão de obra especializada para evitar sanções e garantir conformidade ao atendimento à lei, o que realça a criticidade da gestão informacional na contabilidade (CABELLO; NAKAO, 2021).

Como destacam Castanha e Cazane (2024), a informação é um recurso organizacional de natureza estratégica, e sua gestão adequada contribui para a criação de conhecimento e vantagem competitiva. No ambiente contábil, isso se traduz em maior precisão nos relatórios, cumprimento de obrigações fiscais, redução de custos e análise de desempenho econômico-financeiro.

Assim, a aplicação de princípios da GI na contabilidade visa reduzir o risco informacional e aprimorar a acurácia dos processos decisórios. A integração de técnicas de Inteligência Artificial à GI representa, portanto, uma evolução natural rumo à automação, à eficiência e à transformação digital da gestão contábil.

Inteligência Artificial e sua Aplicação na Contabilidade

A Inteligência Artificial (IA) é um campo da ciência da computação voltado ao desenvolvimento de sistemas e máquinas capazes de simular habilidades do pensamento humano (CANTON et al., 2024). De forma ampla, a IA é definida como um campo da ciência da computação que se concentra no desenvolvimento de sistemas e máquinas capazes de realizar tarefas que exigem inteligência humana, o que em resumo envolve a capacidade das máquinas de aprender, raciocinar, compreender, processar a linguagem natural e tomar decisões (SCHWINDT; COSTA, 2021, *apud* XIMENES DE MELO et al., 2024). Canton et al. (2024), afirma que, o uso da IA pode aprimorar significativamente a análise de grandes volumes de dados e melhorar a tomada de decisões nas organizações.

Embora a discussão sobre os impactos da Inteligência Artificial (IA) na sociedade seja atual, sua história remonta à própria origem do computador, na primeira metade do século XX. O matemático Claude Shannon publicou, em 1937, em sua tese de mestrado intitulada *A Symbolic Analysis of Relay and Switching Circuits*. Neste trabalho, Shannon provou que circuitos elétricos poderiam realizar operações lógicas booleanas, estabelecendo o fundamento para a construção física dos computadores digitais (SHANNON, 1937). Posteriormente, em 1948, em sua obra seminal *A Mathematical Theory of Communication*, Claude Shannon consolidou as bases da Teoria da Informação ao introduzir o conceito de 'bit' e quantificar a entropia dos dados (incerteza dos dados). Essas contribuições permitiram que a informação fosse processada de forma quantitativa e estatística, viabilizando a execução de algoritmos complexos que sustentam a IA moderna (SHANNON, 1948). Essa fundamentação converge diretamente com o objetivo precípua da Contabilidade: a redução da assimetria informacional. Assim como a teoria de Shannon busca mitigar a incerteza na transmissão de dados, a contabilidade utiliza a informação para prover suporte à decisão, garantindo que investidores e gestores possuam uma base factual sólida e confiável.

O matemático britânico Alan Turing propôs, em seu artigo seminal *Computing Machinery and Intelligence* (1950), o que se tornaria o marco fundador da IA: o Teste de Turing. O objetivo era avaliar se uma máquina seria capaz de exibir comportamento inteligente equivalente ao humano. Para isso, Turing adaptou o chamado “Jogo da Imitação”, substituindo um dos participantes humanos por um computador, de modo

que os outros dois tentassem determinar se o terceiro elemento seria humano ou máquina. O estudo não questionava se o computador era 'inteligente', mas se poderia se passar por um humano. Nesse contexto, Turing levantou a questão fundamental: “Máquinas podem pensar?” (SOBREIRA, 2025)

Em 1956, John McCarthy cunhou o termo 'Inteligência Artificial' durante um *summer camp*, enquanto atuava como professor assistente de matemática na Faculdade de Dartmouth (KLINE, 2011). Na ocasião, ao solicitar apoio financeiro à Fundação Rockefeller, McCarthy propôs a realização de um encontro com dez pesquisadores que se dedicariam, ao longo de dois meses, a diferentes problemas de pesquisa. Ao reunir matemáticos para resolver desafios comuns, o evento passou a ser considerado o marco fundador da área de pesquisa, denominada por McCarthy, na documentação enviada à fundação, de 'Inteligência Artificial' (MCCARTHY, 1955), estabelecendo as bases formais para os estudos na área e consolidando a visão de que a inteligência poderia ser decomposta em processos de tratamento de informação. (SOBREIRA, 2025)

A partir da década de 1970, a pesquisa em Inteligência Artificial passou a se concentrar em áreas específicas, incluindo o Processamento de Linguagem Natural (PLN), cujo objetivo era desenvolver sistemas capazes de compreender, interpretar e gerar linguagem humana (JURAFSKY; MARTIN, 2020). Inicialmente, os estudos em PLN focaram em análise sintática, tradução automática e reconhecimento de padrões textuais. Com o avanço de técnicas estatísticas e computacionais nas décadas seguintes, especialmente nos anos 1990, essa subárea passou a permitir a análise de grandes volumes de textos e dados não estruturados, estabelecendo bases essenciais para aplicações modernas em diversos setores, inclusive na contabilidade, onde a extração automática de informações de documentos e relatórios financeiros tornou-se viável (JURAFSKY; MARTIN, 2020; CASELI; NUNES, 2023).

Com a consolidação das subáreas da IA, especialmente o PLN, tornou-se possível aplicar essas tecnologias em áreas como Negócios, Gestão e Contabilidade, permitindo a automação e análise avançada de informações financeiras. Essa evolução possibilita que a IA automatize tarefas repetitivas e forneça *insights* estratégicos a partir da análise de grandes volumes de dados, promovendo maior eficiência e suporte à tomada de decisão.

A integração da IA na contabilidade apresenta grande potencial para automatizar tarefas repetitivas, aumentar a precisão dos dados e viabilizar análises

mais sofisticadas (XIMENES DE MELO et al., 2024). Essa automação permite que os profissionais contábeis concentrem seus esforços em atividades analíticas e estratégicas, liberando-os de tarefas manuais e demoradas (HASAN, 2022; SILVA, 2022). Entre as principais aplicações na contabilidade estão o cálculo de tributos, a identificação de pontos de auditoria, a sugestão de ações preventivas e a automação de processos (XIMENES DE MELO et al., 2024).

Entre as principais subáreas da IA aplicadas ou com potencial de aplicação na contabilidade, destacam-se:

- i. **Aprendizado de Máquina (Machine Learning – ML):** desenvolvimento de algoritmos que permitem aos computadores aprender a partir de dados. É essencial para análises preditivas, detecção de anomalias e identificação de fraudes em demonstrações financeiras (ARAUJO; CORNACCHIONE, 2024; HASAN, 2022).
- ii. **Processamento de Linguagem Natural (Natural Language Processing – NLP):** permite que os computadores compreendam e interpretem a linguagem humana. No contexto contábil, é útil para processar grandes volumes de dados não estruturados (como documentos e relatórios) e extrair informações relevantes, superando limitações das abordagens tradicionais baseadas em dados estruturados (ARAUJO; CORNACCHIONE, 2024; HASAN, 2022).
- iii. **Automação Robótica de Processos (Robotic Process Automation – RPA):** softwares (bots) configurados para imitar ações humanas e automatizar tarefas repetitivas baseadas em regras. Exemplos incluem lançamento contábil, reconciliação de contas e automação do processo de contas a pagar (HASAN, 2022; SILVA; COSTA; PIMENTA, 2022).
- iv. **Sistemas Especialistas (Expert Systems):** replicam o conhecimento e a experiência de especialistas humanos para resolver problemas específicos, como auditoria, planejamento tributário e análise de risco de crédito (XIMENES DE MELO et al., 2024).

Atualmente, muitas soluções de IA no setor contábil concentram-se em auditoria e análises financeiras, devido à dificuldade humana de processar grandes volumes de documentos. As Big Four (Deloitte, EY, KPMG e PwC) investem ativamente em IA e RPA para reconhecimento automático de dados, escrituração de

documentos e geração de relatórios, buscando maior eficiência, como é o caso do Halo, desenvolvido pela PWC, e dos softwares Argus e Optix, elaborados pela Deloitte (DELOITTE, 2025; SILVA; COSTA; PIMENTA, 2022). Apesar desses avanços, lacunas de pesquisa e aplicação ainda existem, especialmente no setor fiscal, em que a IA é mais utilizada por órgãos governamentais para coibir a evasão fiscal do que para apoiar empresas na classificação e apuração correta dos tributos (XIMENES DE MELO et al., 2024).

No contexto contábil, os Modelos de Linguagem Grande (LLMs), como o GPT-3, passaram a desempenhar um papel relevante na transformação digital das organizações (CANTON et al., 2024). Esses modelos são sistemas de inteligência artificial treinados com grandes volumes de texto, capazes de compreender, gerar e interpretar a linguagem humana de forma coerente. Um exemplo amplamente conhecido é o ChatGPT, que utiliza LLM para responder perguntas, gerar textos e apoiar processos de tomada de decisão. Segundo Canton et al. (2024), a IA tem sido aplicada em áreas diversas — da medicina à gestão pública — visando otimização de processos e suporte à decisão. Na contabilidade, a LLM permite automatizar tarefas repetitivas, como lançamentos e reconciliações, além de gerar análises preditivas de desempenho e riscos, oferecendo suporte analítico estratégico aos profissionais (BROWN et al., 2020; CABRAL, 2025; CANTON et al., 2024).

Araujo e Cornacchione (2024) enfatizam que, além da automação, a IA amplia a capacidade analítica dos profissionais contábeis, convertendo dados brutos em informações estratégicas. No entanto, essa capacidade depende da qualidade das bases de dados e da confiabilidade das respostas geradas. Por isso, abordagens que combinam geração e recuperação de informações, como a técnica RAG, tornam-se promissoras para o setor contábil, que exige precisão, rastreabilidade e segurança na gestão de dados.

Retrieval-Augmented Generation (RAG)

O método Retrieval-Augmented Generation (RAG) foi proposto por Lewis et al. (2020) como uma técnica híbrida que combina Modelos de Linguagem de Grande Escala (LLM) com mecanismos de recuperação de informação. Essa abordagem combina a geração de texto por modelos de linguagem com a recuperação de


informações a partir de bases de dados externas, permitindo respostas mais precisas e contextualizadas (LEWIS et al., 2020).

O RAG destaca-se pela busca em reduzir as chamadas “alucinações” — respostas fabricadas ou incorretas — típicas de modelos puramente generativos (BROWN et al., 2020; LEWIS et al., 2020). O LLM tradicional armazena todo seu conhecimento de forma implícita nos parâmetros aprendidos durante o treinamento, sem acesso a fontes externas no momento da geração da resposta. Por isso, esses modelos frequentemente apresentam limitações para responder perguntas específicas de um domínio: os dados de treinamento podem estar desatualizados em relação ao momento da consulta, o tema solicitado pode ser altamente especializado ou a informação pode estar presente em fontes privadas e não acessíveis publicamente durante o treinamento (MOUSCHOUTZI, 2025).

O RAG, por outro lado, consulta bases de dados externas ao treinamento original do modelo antes de gerar a resposta, garantindo maior precisão, rastreabilidade e transparência. Essa característica torna o método especialmente relevante em domínios que demandam informações verificáveis, como o jurídico, médico e contábil (ARAUJO; CORNACCHIONE, 2024; LEWIS et al., 2020).

Na prática, o RAG funciona em duas etapas principais. Na primeira, de recuperação (retrieval), o sistema busca trechos relevantes em uma base de dados vetorial, a partir da similaridade semântica entre a consulta do usuário e os documentos previamente indexados. Na segunda, de geração (generation), o LLM produz a resposta com base nesses trechos recuperados, mantendo a fluidez e a contextualização típicas do modelo, mas agora ancorada em evidências textuais concretas e rastreáveis (LEWIS et al., 2020). Esse pipeline permite que a resposta final seja, simultaneamente, factualmente precisa e fundamentada em uma base de conhecimento determinada pelo usuário, sem renunciar à naturalidade discursiva característica dos modelos de linguagem (MOUSCHOUTZI, 2025).

Figura 1 – Pipeline de processamento e geração de respostas via arquitetura RAG.



Fonte: Adaptado de Mouschoutzi (2025).

Além disso, o RAG permite que empresas utilizem suas próprias bases de conhecimento internas — tutoriais, manuais, legislações — como fonte de consulta do modelo, em vez de depender exclusivamente do conhecimento generalista absorvido durante o treinamento do LLM. Dependendo da arquitetura adotada (por exemplo, com modelos de linguagem e bancos de dados vetoriais hospedados em infraestrutura própria), essa característica pode inclusive viabilizar maior controle sobre a exposição de informações sigilosas a serviços de terceiros — um aspecto especialmente relevante em contextos governamentais de soberania de dados, e em domínios como o contábil, que lida rotineiramente com dados protegidos por sigilo legal, fiscal e empresarial.

Relação entre RAG e a Gestão da Informação Contábil

No processo do RAG, a consulta do usuário é submetida ao recuperador, que retorna os documentos mais relevantes. Esses documentos são integrados e enviados ao gerador para produzir a resposta final, mantendo a coerência e a fundamentação factual. Assim, a arquitetura RAG é composta por dois componentes principais:

- i. Recuperador (Retriever): Busca documentos relevantes em uma memória não-paramétrica (índice de documentos ou base de dados), geralmente utilizando técnicas de embeddings vetoriais para medir a similaridade semântica entre a consulta do usuário e os documentos armazenados (LEWIS et al., 2020).

- ii. Gerador (Generator): Recebe os documentos recuperados como contexto adicional, juntamente com a consulta original, e formula uma resposta coerente e fundamentada (LEWIS et al., 2020).

A integração entre o RAG e a Gestão da Informação cria um paradigma de eficiência no tratamento de grandes volumes de dados normativos e técnicos. No contexto contábil, o uso do RAG possibilita consultas rápidas e precisas a bases de conhecimento específicas, reduzindo erros de interpretação e o tempo de busca de informações (ARAUJO; CORNACCHIONE, 2024; LEWIS et al., 2020). A recuperação da informação (*information retrieval*) é, nesse sentido, um componente essencial na Gestão da Informação (GI) e o RAG aprimora diretamente esse processo ao tornar a busca mais eficiente e semanticamente precisa do que os métodos tradicionais baseados em palavras-chave, alinhando-se às demandas da Contabilidade Digital e da Indústria 4.0 (CANTON et al., 2024; HASAN, 2022).

Ao permitir que o contador interaja em linguagem natural com a base de conhecimento da empresa, o RAG atua como um sistema de apoio à decisão, fortalecendo o papel estratégico da contabilidade frente a cenários de alta complexidade documental e regulamentações em constante atualização. Diferentemente dos modelos de linguagem convencionais, que geram respostas exclusivamente a partir de seu conhecimento paramétrico, a arquitetura RAG vincula cada resposta a documentos de origem identificáveis, o que viabiliza, quando essa vinculação é explicitamente exposta ao usuário, maior transparência, governança da informação e rastreabilidade dos dados utilizados na resposta (Lewis et al., 2020).

Essa rastreabilidade, contudo, não é uma propriedade automática de toda implementação RAG, mas depende de o sistema apresentar ao usuário as fontes que fundamentaram cada resposta gerada. Quando essa exposição é assegurada, a inspeção do conhecimento acessado torna-se possível, permitindo verificar se as conclusões apresentadas estão de fato fundamentadas nos documentos recuperados — característica especialmente relevante para mitigar riscos na aplicação de normas fiscais e regulatórias, em que decisões tomadas com base em informação incorreta podem ter consequências legais e financeiras diretas (LEWIS et al., 2020; ARAUJO; CORNACCHIONE, 2024).

Para otimizar a performance da recuperação frente à volatilidade das legislações e à complexidade dos documentos técnicos, o sistema pode ser refinado

com técnicas avançadas de pré e pós-recuperação. Destacam-se a segmentação semântica, que preserva a unidade de sentido dos trechos recuperados, e o *reranking*, que reordena os documentos candidatos por relevância antes da etapa de geração, filtrando ruídos informacionais para garantir que apenas os dados mais pertinentes componham a resposta final (ARAUJO; CORNACCHIONE, 2024).

Em síntese, o RAG mitiga as limitações de alucinação típicas do LLM tradicionais em domínios intensivos em conhecimento, consolidando-se como uma ferramenta estratégica para a modernização dos processos contábeis (CANTON et al., 2024; HASAN, 2022). Sua efetividade nesse propósito, entretanto, está diretamente condicionada à qualidade da arquitetura de recuperação adotada e à forma como o sistema expõe suas fontes ao usuário final — aspectos que constituem o foco da avaliação empírica conduzida neste trabalho, apresentada no Capítulo 4.

3 METODOLOGIA

3.1 Classificação da Pesquisa

A pesquisa é classificada como descritiva e aplicada. É descritiva, pois visa descrever as características, fatos e fenômenos de uma determinada realidade (GERHARDT; SILVEIRA, 2009), o que se manifesta no mapeamento do estado da arte da IA, na arquitetura do protótipo desenvolvido e seus respectivos resultados. É aplicada, pois objetiva gerar conhecimento para utilização prática e dirigida à solução de problemas específicos (GERHARDT; SILVEIRA, 2009), concretizado pelo desenvolvimento do *chatbot* para a gestão de tutoriais.

3.2 Fonte e coleta dos dados

A base de conhecimento do protótipo é composta pelos manuais técnicos e tutoriais operacionais do sistema Sispetro, hospedados no Atlassian Confluence — plataforma corporativa de gestão do conhecimento da empresa Futura Sistemas, proprietária do sistema Sispetro e fonte oficial da documentação do software. A extração foi realizada via API REST da Atlassian, por meio de um script Python (*extract.py*) desenvolvido para este trabalho, que percorreu sistematicamente o espaço de documentação "SPT" e coletou 2.543 páginas em formato HTML, preservando título e URL de origem de cada documento.


Os arquivos HTML foram pré-processados com o auxílio da biblioteca BeautifulSoup, que removeu as *tags* de marcação e demais elementos não textuais, resultando em 2.543 arquivos de texto puro no formato .txt, com codificação UTF-8 para preservação correta dos caracteres da língua portuguesa. Em seguida, cada arquivo foi segmentado em fragmentos de 1.000 caracteres com sobreposição de 200 caracteres entre fragmentos consecutivos, gerando 11.052 fragmentos no total.

Cada fragmento foi convertido em vetor numérico pelo modelo *text-embedding-3-small* da OpenAI e armazenado no Pinecone, banco de dados vetorial em nuvem de alta disponibilidade. Durante as consultas, o sistema recupera os 4 fragmentos mais similares à pergunta do usuário e os envia ao GPT-3.5-turbo, que gera a resposta em linguagem natural. A escolha desse modelo se justifica pela disponibilidade via API, custo acessível e geração textual adequada para um protótipo acadêmico.

3.3 Desenvolvimento do Protótipo RAG

O protótipo foi desenvolvido como uma aplicação web, combinando o backend de processamento em Python com uma interface de conversação construída no framework Streamlit (frontend). A lógica de funcionamento segue o fluxo padrão da arquitetura RAG: ao receber uma pergunta do usuário, o sistema busca no Pinecone os 4 fragmentos mais semanticamente próximos à consulta, monta um prompt estruturado com esses fragmentos como contexto e envia tudo ao GPT-3.5-turbo, que gera a resposta em linguagem natural.

Figura 2 - Fluxo de consulta do protótipo Chatbot Sispetro AI



Fonte: Elaborado pelo autor (2026).

O comportamento do chatbot foi configurado via prompt de sistema — uma instrução invisível ao usuário que define como o modelo deve se comportar. Essa instrução orienta o sistema a realizar uma saudação proativa, responder exclusivamente com base no conteúdo recuperado dos manuais, admitir desconhecimento quando a informação não estiver disponível na base e manter um tom técnico e objetivo nas respostas. Essa restrição é especialmente relevante no contexto contábil, onde uma resposta fabricada sobre um procedimento fiscal ou de auditoria pode gerar consequências legais e financeiras reais.

O protótipo foi publicado na internet por meio de um servidor virtual na Amazon Web Services (AWS Lightsail), acessível pelo domínio chatbotsispetro.com.br, com tráfego protegido pelo protocolo HTTPS. Para garantir a continuidade do serviço, foram implementados dois mecanismos de monitoramento: um serviço externo que verifica a disponibilidade do sistema a cada cinco minutos e envia alertas automáticos em caso de interrupção, e uma tarefa agendada no servidor — configurada via cron, o gerenciador de tarefas nativo de sistemas Linux — que reinicia o serviço automaticamente sempre que uma queda inesperada for detectada, sem necessidade de intervenção manual.

3.4 Procedimentos de validação

A validação do protótipo foi inicialmente planejada para ser conduzida por especialistas externos. Essa alternativa, contudo, dependia da disponibilidade de terceiros, recursos que não puderam ser assegurados dentro do cronograma estabelecido para a conclusão deste trabalho. Optou-se, portanto, por uma autoavaliação sistemática com checagem documental conduzida pelo próprio autor. O que se altera em relação ao desenho original é o agente avaliador, não os critérios de avaliação — que permanecem os mesmos cinco indicadores definidos para este estudo. Para garantir a transparência e permitir auditoria independente, todas as perguntas-teste, as respostas geradas pelo protótipo e os trechos do manual técnico utilizados na checagem foram registrados integralmente no instrumento de validação disponibilizado no Apêndice A deste trabalho. O código-fonte do protótipo, os scripts de extração e ingestão da base de dados e as evidências completas do processo de validação estão igualmente disponíveis no repositório público do projeto no [GitHub](https://github.com), cujo link encontra-se no Apêndice A, permitindo que qualquer leitor inspecione a implementação técnica e audite de forma independente os resultados obtidos.

As perguntas-teste foram elaboradas a partir da análise dos títulos das 2.543 páginas da base de conhecimento, garantindo que as consultas refletissem funcionalidades realmente presentes nos manuais do Sispetro. Foram organizadas em três categorias: **perguntas diretas**, que avaliam a precisão do sistema em procedimentos pontuais descritos em uma única página da base; **perguntas de síntese**, que exigem a combinação de informações distribuídas em mais de um trecho; e **perguntas-armadilha**, referentes a funcionalidades plausíveis para um

sistema de gestão, mas inexistentes na base documental, com o objetivo de verificar se o protótipo reconhece corretamente os limites do seu próprio conhecimento.

Cada pergunta foi submetida ao protótipo por meio do domínio público em produção (chatbotsispetro.com.br), reproduzindo as condições reais de uso do sistema. A resposta gerada foi então confrontada com o conteúdo da página correspondente no [Atlassian Confluence](#) — fonte oficial dos manuais técnicos do Sispetro e fonte única da verdade para este trabalho — permitindo identificar com precisão se a resposta estava ancorada na base documental ou se apresentava desvios, omissões ou informações fabricadas — alucinações.

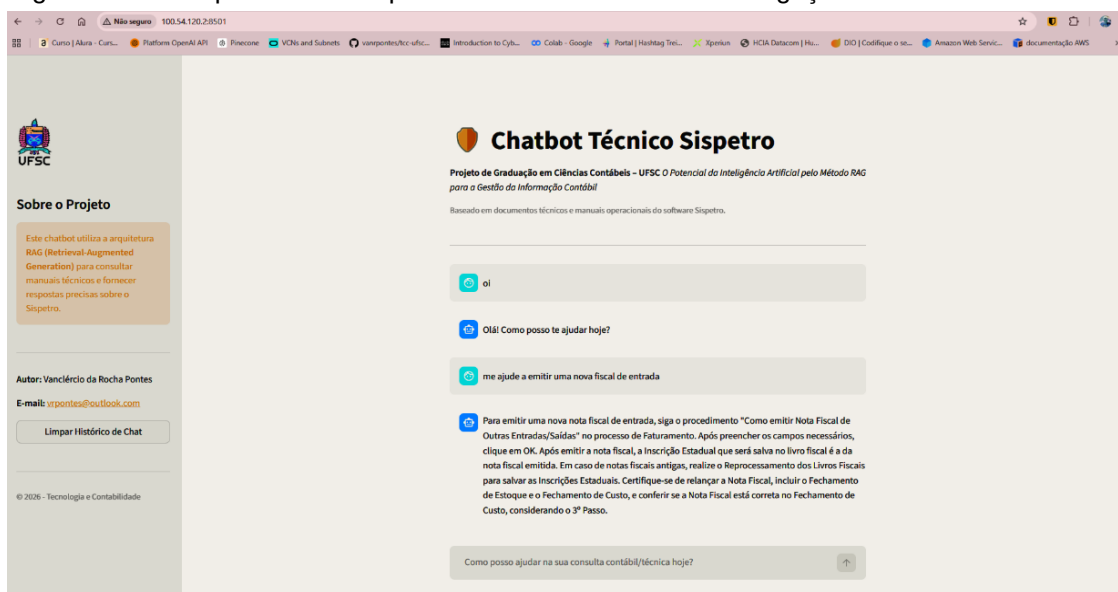
Os resultados foram registrados e analisados com base em cinco critérios de desempenho, pontuados em escala de 1 a 5, e sintetizados por meio de estatística descritiva simples — média aritmética por critério e por categoria de pergunta. Os critérios adotados foram: **precisão semântica**, que mede a correspondência entre a resposta gerada e o conteúdo original da base; **relevância contextual**, que avalia a adequação da resposta à pergunta formulada; **clareza e coerência textual**, que verifica a qualidade linguística da resposta; **usabilidade**, que avalia a interface do sistema como um todo; e **potencial de aplicação**, que avalia a viabilidade prática da ferramenta para a gestão da informação. Os três primeiros critérios são fundamentados nas métricas de fidelidade e fluidez de sistemas RAG propostas por Lewis et al. (2020); os dois últimos baseiam-se nos princípios de usabilidade (UX – *User eXperience*) e aceitação de sistemas de informação de Pereira et al. (2011).

4 ANÁLISES DOS RESULTADO

4.1 Descrição do Ambiente Operacional e Interface

O protótipo desenvolvido, denominado Chatbot Sispetro AI, foi materializado em uma interface web simples e objetiva, construída com o framework Streamlit. Como observado na Figura 3, os testes iniciais foram realizados em ambiente de homologação, utilizando o endereço de IP para validar o funcionamento do sistema. No painel lateral, foram inseridos elementos institucionais, como o brasão da Universidade Federal de Santa Catarina (UFSC), uma síntese dos objetivos do projeto, a identificação da autoria e um botão para reiniciar a conversa, permitindo o início de novas sessões sem interferência do histórico anterior.

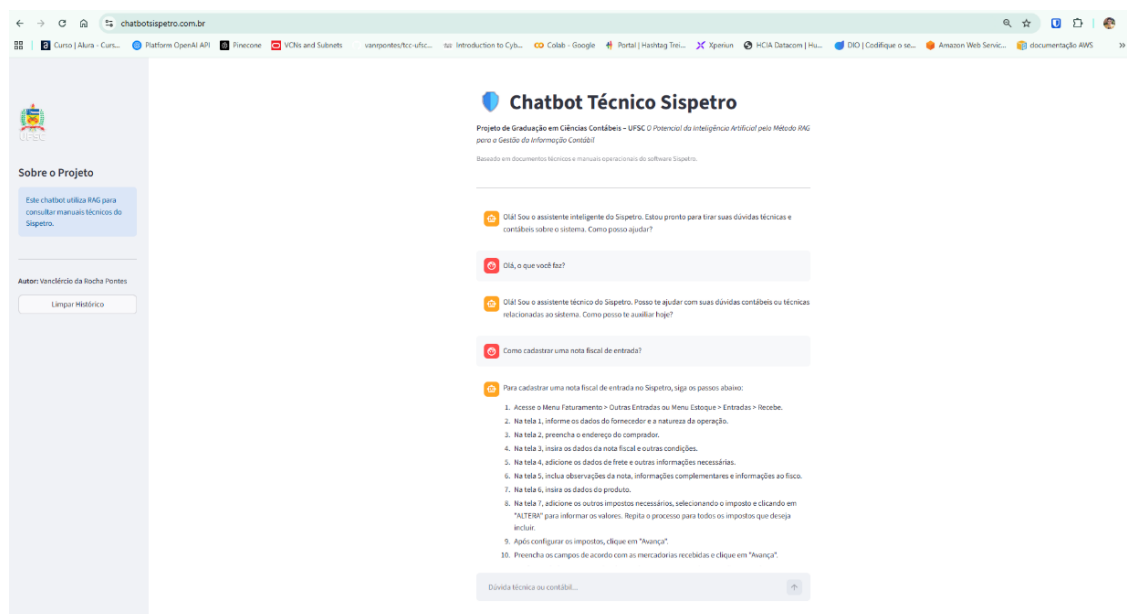
Figura 3 – Protótipo Chatbot Sispetro AI em ambiente de homologação via IP dinâmico



Fonte: Elaborado pelo autor (2026).

O sistema foi configurado para atuar como um assistente técnico contábil especializado nos manuais do Sispetro, admitindo desconhecimento quando a informação solicitada não estiver disponível na base documental. Esse processo culminou na versão 1.0 do sistema, agora operando sob domínio próprio e com tráfego protegido pelo protocolo HTTPS, conforme apresentado na Figura 4.

Figura 4 - Protótipo Sispetro AI em ambiente de produção com domínio personalizado – v1.0



Fonte: Elaborado pelo autor (2026).

4.2 Composição da Amostra de Validação

A amostra de perguntas-teste foi construída a partir de um levantamento dos títulos das 2.543 páginas da base de conhecimento, o que permitiu identificar os principais módulos funcionais cobertos pela documentação técnica do Sispetro: Vendas, Fiscal/Nota Fiscal Eletrônica, Financeiro, Estoque, Integração/Importação de dados, Contabilidade/Controladoria, Configuração e Cadastro, Compras, Relatórios e Produção/Fabricação.

Com base nesse levantamento, foram elaboradas 24 perguntas-teste, distribuídas proporcionalmente entre os módulos e organizadas em três categorias: **perguntas diretas**, que avaliam a precisão do sistema em procedimentos pontuais descritos em uma única página da base; **perguntas de síntese**, que exigem a combinação de informações de mais de uma página do manual; e **perguntas-armadilha**, referentes a funcionalidades plausíveis para um sistema de gestão, porém inexistentes na base documental, com o objetivo de verificar se o protótipo reconhece os limites do próprio conhecimento em vez de produzir respostas fabricadas.

Durante a checagem documental, identificou-se que duas das seis perguntas originalmente classificadas como armadilha referiam-se, na verdade, a funcionalidades reais e documentadas do Sispetro — "Como configuro a integração do Sispetro com o WhatsApp Business para notificar clientes?" e "Qual é o procedimento para emitir Nota Fiscal de Serviço (NFS-e) no Sispetro?". Ao confrontar

as respostas do protótipo com o Atlassian Confluence, constatou-se que o sistema contém essas funcionalidades, com páginas próprias e links verificáveis fornecidos pelo próprio chatbot. As duas perguntas foram reclassificadas para a categoria direta, e a amostra final ficou composta por 11 perguntas diretas, 9 de síntese e 4 armadilhas. Esse rebalanceamento é registrado com transparência por constituir, em si, um achado relevante: evidenciando que mesmo um instrumento cuidadosamente construído está sujeito a imprecisões quando o conhecimento do avaliador sobre uma base de mais de 2.500 páginas é incompleto.

4.3 Resultados

A aplicação das 24 perguntas-teste resultou em uma média geral de 3,54 para o critério de **precisão semântica**, 3,83 para **relevância contextual**, 4,00 para **clareza e coerência textual**, 4,00 para **usabilidade** e 3,00 para **potencial de aplicação**, em uma escala de 1 a 5. A Tabela 1 apresenta a síntese desses resultados.

Tabela 1 - Médias gerais por critério de avaliação (n=24)

Critério	Média (1-5)
Precisão semântica	3,54
Relevância contextual	3,83
Clareza e coerência textual	4,00
Usabilidade (avaliação única do protótipo)	4,00
Potencial de aplicação	3,00

Fonte: Elaborado pelo autor (2026), com base no instrumento de validação disponível no Apêndice A.

Para aprofundar a análise, os mesmos critérios foram segmentados por categoria de pergunta, permitindo identificar de forma mais precisa em quais situações o protótipo performa melhor e onde apresenta maior fragilidade. A Tabela 2 apresenta essa segmentação.

Tabela 2 - Médias por critério e categoria de pergunta

Critério	Diretas (1-5)	Síntese	Armadilha
Precisão semântica	4,00	3,67	2,00
Relevância contextual	4,18	3,89	2,75
Clareza e coerência textual	4,45	3,67	3,50
Usabilidade (avaliação única)	4,00	4,00	4,00
Potencial de aplicação	3,45	2,89	2,00

Fonte: elaborado pelo autor (2026), com base no instrumento de validação disponível no Apêndice A.

Quando os resultados são segmentados por categoria de pergunta, observa-se uma diferença relevante e consistente em todos os critérios. As perguntas **diretas** obtiveram a média mais alta de **precisão semântica** (4,00), seguidas pelas perguntas de **síntese** (3,67) e pelas **perguntas-armadilha** (2,00). O mesmo padrão se repete no critério de **potencial de aplicação**, em que as perguntas **diretas** atingiram 3,45, as de **síntese** 2,89, e as **armadilhas** 2,00. Esse padrão decrescente indica que o protótipo apresenta desempenho mais consistente quanto menor a necessidade de combinar informações de múltiplas páginas da base documental, e mais frágil quanto maior a exigência de síntese ou de reconhecimento dos próprios limites de conhecimento.

Das quatro **perguntas-armadilha** remanescentes, o protótipo admitiu corretamente o desconhecimento em apenas uma ocorrência, o que corresponde a uma taxa de 25% de admissão correta. Nas três ocorrências restantes, o sistema respondeu com procedimentos genéricos e plausíveis, porém sem nenhuma correspondência verificável na fonte: ao ser questionado sobre integração com o ChatGPT para geração automática de relatórios, sobre autenticação em dois fatores para login de usuários e sobre a existência de aplicativo mobile nativo, o chatbot produziu, em cada caso, uma sequência de passos tecnicamente coerente e redigida com a mesma confiança das respostas corretas, sem qualquer sinalização de incerteza. Esse comportamento caracteriza o fenômeno de alucinação, discutido com maior profundidade na seção 4.4.

Para ilustrar a amplitude do desempenho observado, destacam-se três casos representativos, com o conjunto completo das 24 ocorrências disponível no Apêndice A.

Caso 1 – Desempenho satisfatório (pergunta direta, nota 5 em precisão semântica). À pergunta "Como habilitar um relatório para geração em arquivo no Gerenciador de Relatórios?", o protótipo reproduziu com fidelidade os cinco passos descritos no manual técnico, sem omissões nem informações não verificadas. Trata-se da resposta de maior fidelidade documental da amostra, favorecida pela concentração de toda a instrução relevante em uma única página da base de conhecimento.

Caso 2 – Reconhecimento correto de limite (pergunta-armadilha, nota 5 em todos os critérios). Questionado sobre a existência de aplicativo mobile nativo

para Android e iOS, o protótipo respondeu corretamente que a funcionalidade não existe, descreveu a alternativa real disponível — o SispetroApp, acessível via navegador com leitura de QR Code — e indicou a fonte documental correspondente. Esse caso representa o comportamento ideal esperado de um sistema RAG: reconhecer o limite do próprio conhecimento sem comprometer a utilidade da resposta.

Caso 3 – Desvio crítico (pergunta direta, nota 2 em precisão semântica e nota 1 em potencial de aplicação). À pergunta "Como cancelar uma Nota Fiscal Eletrônica no Sispetro?", o protótipo descreveu, de forma consistente em três execuções distintas, o procedimento de Sincronização de NF-e com a SEFAZ — uma funcionalidade real do sistema, porém destinada à reconciliação de status, não ao cancelamento. O procedimento correto, acessado pelo botão "Cancela" na mesma tela, não foi mencionado em nenhuma das três execuções. Esse caso é examinado em profundidade na seção 4.4.

4.4 Discussão dos Resultados

Os resultados indicam que o protótipo apresenta desempenho satisfatório em tarefas de recuperação pontual, com médias superiores a 4,0 em **precisão semântica** e **relevância contextual** no subconjunto de **perguntas diretas**, alinhando-se ao que Lewis et al. (2020) descrevem como a vantagem central de arquiteturas RAG: fundamentar as respostas em uma base documental externa, em vez de depender exclusivamente do conhecimento do modelo de linguagem. A média de 4,00 em **clareza e coerência textual** confirma que o sistema gera texto bem estruturado mesmo nos casos em que o conteúdo factual apresentou desvios — o que reforça a necessidade de o usuário contábil sempre conferir a fonte original antes de executar um procedimento. O desempenho mais frágil no critério de **potencial de aplicação** (média de 3,00) é coerente, uma vez constatado que uma resposta pode ser textualmente impecável e ainda assim ter baixa aplicabilidade prática, caso omita informações necessárias para a execução completa da tarefa.

A análise qualitativa das 24 interações permitiu identificar três padrões de falha recorrentes, presentes em 11 dos 24 testes (45,8% da amostra).

Padrão 1 – Competição semântica entre páginas vizinhas (3 ocorrências). Em três perguntas diretas, o sistema recuperou o conteúdo de uma página errada — não porque a informação correta estivesse ausente da base, mas porque outra página usava palavras mais próximas às da pergunta. O caso mais ilustrativo é o Caso 3: à pergunta sobre cancelamento de NF-e, o sistema foi atraído pela página "Manutenção de Nota Fiscal", cujo vocabulário (SEFAZ, DANFE, sincronização) tem maior proximidade com os termos da consulta do que a página correta, onde a instrução principal — o botão "Cancela" — aparece em apenas um parágrafo ao final de um documento longo. Padrão equivalente foi observado nas perguntas sobre Vale Pedágio e sobre o módulo de Controladoria. A causa é estrutural: o mecanismo de busca prioriza a densidade de palavras relacionadas ao tema, não necessariamente a página que contém a resposta correta. Documentos tecnicamente corretos, mas com instruções práticas diluídas em textos longos e predominantemente normativos, tendem a prejudicar o mecanismo de recuperação, independentemente da qualidade do modelo de linguagem utilizado — o que reforça o princípio conhecido em sistemas de informação como *garbage in, garbage out*: a qualidade da saída de qualquer sistema depende diretamente da qualidade e da organização dos dados de entrada.

Padrão 2 – Omissão de pré-requisitos de configuração (5 ocorrências). Em cinco das nove perguntas de síntese — referentes ao reprocessamento de notas fiscais para os Livros Fiscais, à cobrança eletrônica, ao acerto automático de estoque zero, à geração do arquivo DAC e à alteração de preços em pedidos de venda — o protótipo descreveu corretamente o fluxo operacional principal, mas omitiu etapas de configuração que constituem pré-requisito para a execução completa do procedimento. Cabe ressaltar que esse comportamento não configura necessariamente um erro do sistema: o protótipo respondeu de forma literal ao que foi perguntado, sem se ater a configurações ou parametrizações prévias não mencionadas na consulta. A limitação reside, portanto, na forma como a pergunta foi formulada — e não na capacidade do sistema de recuperar a informação. Para um contador, isso reforça a importância de formular consultas completas e de conferir a fonte original antes de executar qualquer procedimento, embora a natureza da

pergunta exigisse uma combinação de informações distribuídas em mais de um trecho da base documental.

Padrão 3 – Respostas fabricadas na ausência de informação (3 ocorrências). Nas três perguntas-armadilha em que o protótipo falhou, o sistema não reconheceu que a funcionalidade não existia na base e gerou um procedimento genérico, redigido com a mesma confiança das respostas corretas. O caso mais revelador é o da pergunta sobre autenticação em dois fatores: a base documental contém uma funcionalidade de segurança relacionada — autenticação facial de motoristas no módulo de autoatendimento — mas o sistema não a recuperou, pois, a distância entre os termos da pergunta ("dois fatores", "2FA") e os termos da página real ("biometria facial") foi suficiente para impedir a recuperação. A causa é que a instrução para admitir desconhecimento está apenas no texto de configuração do sistema, sem nenhum mecanismo que bloqueie automaticamente a resposta quando o conteúdo recuperado é insuficiente. Este é o padrão de falha mais crítico identificado nesta pesquisa: diferentemente dos demais, em que o sistema ao menos recupera informações reais da base — ainda que incorretas ou incompletas — aqui o protótipo fabrica uma resposta inexistente com o mesmo nível de confiança textual das respostas corretas, sem qualquer sinalização de incerteza ao usuário. Em um contexto contábil, onde decisões tomadas com base em informação incorreta podem ter consequências legais e financeiras diretas, esse comportamento representa o risco mais relevante de qualquer sistema RAG em produção.

5. CONCLUSÕES, LIMITES E RECOMENDAÇÕES

Este trabalho investigou o potencial da Inteligência Artificial, especificamente por meio da arquitetura RAG, para otimizar a gestão da informação contábil. Esse potencial foi analisado na prática através do desenvolvimento e da validação do protótipo Chatbot Sispetro AI, um assistente virtual criado para responder a dúvidas técnicas com base nos manuais do sistema ERP Sispetro. Este capítulo encerra a pesquisa apresentando as principais conclusões, as limitações do estudo e as recomendações para trabalhos futuros.

5.1 Conclusões

Os resultados obtidos confirmam que o objetivo geral do trabalho foi atingido. O protótipo demonstrou ser uma ferramenta viável para apoiar o cotidiano contábil, com desempenho satisfatório em consultas diretas e pontuais — média de 4,00 em precisão semântica e 4,00 em clareza e coerência textual — e desempenho progressivamente mais frágil conforme aumenta a complexidade da consulta, conforme evidenciado pelo padrão decrescente observado na Tabela 2.

A validação revelou, contudo, que a eficiência do sistema não é uniforme. Em consultas de síntese, que exigem a combinação de informações distribuídas em mais de uma página do manual, a precisão semântica caiu para 3,67. Nas perguntas-armadilha, o sistema reconheceu corretamente o próprio limite de conhecimento em apenas 25% dos casos, gerando respostas fabricadas nas demais ocorrências com o mesmo nível de confiança textual das respostas corretas. Esse comportamento, identificado como o padrão de falha mais crítico da pesquisa, representa um risco real em contextos contábeis onde decisões tomadas com base em informação incorreta podem ter consequências legais e financeiras diretas.

Mais relevante do que os números isolados é o diagnóstico que eles produzem: as falhas do sistema não são aleatórias. Os três padrões identificados no Capítulo 4 — competição semântica entre páginas vizinhas, omissão de pré-requisitos de configuração e respostas fabricadas na ausência de informação — estão ligados a componentes específicos e identificáveis do sistema, o que torna possível corrigi-los de forma direcionada. Para empresas e escritórios que avaliam a adoção de ferramentas baseadas em RAG, esse mapa de fragilidades representa o resultado

mais valioso desta pesquisa: saber onde o sistema falha é o primeiro passo para usá-lo com segurança.

A lição central para o profissional contábil reside em compreender o funcionamento e os limites dessas ferramentas para interagir com elas de forma consciente, segura e complementar. A inteligência artificial é capaz de processar volumes massivos de documentos em segundos, mas carece do discernimento contextual e da responsabilidade ética que definem a tomada de decisão profissional. O contador que compreende essa distinção está mais bem preparado para extrair o melhor dessas tecnologias sem renunciar ao que é insubstituível no seu trabalho.

5.2 Limitações

Como qualquer pesquisa aplicada, este trabalho enfrentou limitações que devem ser consideradas. A principal delas é a ausência de avaliadores externos: devido a restrições de cronograma, a validação foi conduzida pelo próprio autor em formato de autoavaliação sistemática com checagem documental, em vez de ser aplicada por especialistas independentes como planejado originalmente. Para mitigar essa limitação e assegurar a transparência do processo, o registro completo das 24 perguntas-teste, das respostas geradas pelo protótipo e dos trechos correspondentes dos manuais foi disponibilizado integralmente no Apêndice A deste trabalho. O código-fonte do protótipo e as evidências completas do processo de validação estão igualmente disponíveis no repositório público do projeto no GitHub, cujo link encontra-se no Apêndice A, permitindo que qualquer leitor reproduza o julgamento realizado e audite de forma independente a correspondência entre cada resposta e sua fonte documental.

A segunda limitação refere-se à abrangência da amostra de validação. As 24 perguntas-teste cobriram os principais módulos funcionais do Sispetro de forma proporcional, mas representam uma fração da base documental de 2.543 páginas. Os padrões identificados são consistentes e replicáveis, mas não podem ser generalizados como representativos de todo o comportamento possível do sistema sem uma amostra mais ampla.

5.3 Recomendações para Trabalhos Futuros

Os três padrões de falha identificados no Capítulo 4 apontam para ajustes técnicas específicas que podem orientar pesquisas futuras. Para o **Padrão 1**, de **competição semântica** entre páginas vizinhas, recomenda-se a introdução de um **filtro de reordenação semântica** — conhecido como *reranking* — entre a etapa de recuperação e a geração da resposta. Nesse modelo, o sistema recuperaria um conjunto maior de fragmentos ($n=10$) e um segundo filtro os reordenaria pela coerência real com a consulta antes de enviá-los ao modelo de linguagem, reduzindo a interferência de páginas com vocabulário semelhante, mas conteúdo operacionalmente distinto.

Para o **Padrão 2**, de **omissão de pré-requisitos de configuração**, sugere-se programar o sistema para realizar buscas complementares automáticas direcionadas a termos como "configuração", "perfil" e "habilitar" sempre que detectar uma pergunta sobre fluxos operacionais, ampliando o contexto recuperado para além da instrução principal.

Para o **Padrão 3**, de **respostas fabricadas na ausência de informação**, recomenda-se **implementar um corte matemático de relevância**: se nenhum fragmento da base atingir um limiar (*threshold*) mínimo de similaridade com a consulta do usuário, o sistema exibe automaticamente uma mensagem de desconhecimento, bloqueando o envio da pergunta ao modelo de linguagem e eliminando a possibilidade de respostas inventadas.

Por fim, recomenda-se a validação do protótipo com usuários reais — contadores e profissionais que utilizem o Sispetro no dia a dia — aplicando o mesmo instrumento de 24 perguntas e comparando a percepção prática dos profissionais com os resultados da autoavaliação técnica realizada neste trabalho. Essa etapa conferiria validade externa ao estudo e permitiria identificar dimensões de usabilidade e aplicabilidade que a autoavaliação, por definição, não é capaz de capturar.

REFERÊNCIAS

- ACSA, Mylla. **A ascensão da inteligência artificial no cotidiano brasileiro: como a tecnologia está transformando o mercado e o dia a dia.** CNN Brasil, São Paulo, 10 mar. 2025. Disponível em: <https://www.cnnbrasil.com.br/esportes/apostas/responsabilidade-no-jogo/a-ascensao-da-inteligencia-artificial-no-cotidiano-brasileiro/> Acesso em: 10 out. 2025.
- ARAUJO, Marcelo Henrique; CORNACCHIONE, Edgard. **Reflexões sobre o uso de inteligência artificial na contabilidade gerencial: oportunidades, desafios e riscos.** Revista de Contabilidade e Organizações, São Paulo, v. 18, n. 1, p. 1-22, 2024.
- BARBOSA, Ricardo Rodrigues. Gestão da informação e gestão do conhecimento: evolução e conexões. **Perspectivas em Ciências da Informação**, Belo Horizonte, v. 25, n. 1, p. 1-19, fev. 2020.
- BARDIN, Laurence. **Análise de conteúdo.** Lisboa: Edições 70, 2011.
- BROWN, Tom B. et al. **Language models are few-shot learners.** In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS, 34., 2020, Vancouver: NeurIPS, 2020.
- CABELLO, Otávio Gomes; NAKAO, Silvio Hiroshi. **Complexidade, conformidade e arrecadação tributária.** Economia e Sociedade, Campinas, v. 30, n. 3, p. 773-798, dez. 2021.
- CABRAL, João Pedro Freire. **Chatbot inteligente para acesso a regulamentos acadêmicos: um sistema de recuperação de informações baseado em RAG.** 2025. Trabalho de Conclusão de Curso (Graduação em [confirmar curso]) – Universidade Federal do Rio Grande do Norte, Natal, 2025.
- CANTON, Eduardo Helou Giraldele; MIGUEL, Renan Piranga. **Inteligência artificial na gestão da informação.** 2024. Trabalho de Conclusão de Curso (Curso Superior de Tecnologia em Tecnologia da Informação) – Faculdade de Tecnologia de Assis Prof. Dr. José Luiz Guimarães, Assis, 2024.
- CASELI, Helena de Medeiros; NUNES, Maria das Graças Volpe (orgs.). **Processamento de Linguagem Natural.** 1. ed. São Paulo: Blucher, 2023.
- CASTANHA, Rafael Gutierrez; CAZANE, Ana Livia. **A evolução das tendências**

de pesquisa em gestão da informação e gestão do conhecimento: uma análise de 1993 a 2023. Revista Eletrônica de Administração (Porto Alegre), Porto Alegre, v. 30, n. 3, p. 1439-1461, set./dez. 2024.

Deloitte. **Auditing in the AI era.** Disponível em: <https://www.deloitte.com/middle-east/en/our-thinking/mepov-magazine/sustainable-strategies/auditing-in-the-ai-era.html>. Acesso em: 13 out. 2025.

FUTURA TECNOLOGIA. **Sispetro – Espaço SPT.** Atlassian Confluence, 2026. Disponível em: <https://futura.atlassian.net/wiki/spaces/SPT/overview?homepageId=2875588609>. Acesso em: 21 jun. 2026.

GARCIA, Elias; CORBARI, Eliane Mariana; AGUIRRE JUNIOR, Dirceu; CISLAGHI, Patricia; TORRES, Annelise. **A Importância da divulgação contábil mensurada ao Fair Value.** Revista Contemporânea de Contabilidade, Florianópolis, v. 4, n. 7, p. 115-132, jan./jun. 2007.

GERHARDT, Tatiana Engel; SILVEIRA, Denise Tolfo. **Métodos de pesquisa.** Coordenado pela Universidade Aberta do Brasil – UAB/UFRGS e pelo Curso de Graduação Tecnológica – Planejamento e Gestão para o Desenvolvimento Rural da SEAD/UFRGS. Porto Alegre: Editora da UFRGS, 2009.

HASAN, A. R. Artificial Intelligence (AI) in Accounting & Auditing: A Literature Review. **Open Journal of Business and Management**, v. 10, n. 4, p. 1823-1845, 2022.

HOSS, Osni et al. **Contabilidade: ensino e decisão.** São Paulo: Atlas, 2008.

JURAFSKY, Daniel; MARTIN, James H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition.** 3. ed. [S.l.: s.n.], 2025. Disponível em: <https://web.stanford.edu/~jurafsky/slp3/> Acesso em: 12 out. 2025.

KLINE, Ronald. Cybernetics, Automata Studies, and the Dartmouth Conference on Artificial Intelligence. **IEEE Annals of the History of Computing**, v. 33, n. 4, p. 5-16, 2011.

LEWIS, Patrick et al. **Retrieval-Augmented Generation for Knowledge-Intensive**

NLP Tasks. CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS, 2020, Vancouver, Canada.

McCARTHY, John; MINSKY, Marvin; ROCHESTER, Nathaniel; SHANNON, Claude E. **A proposal for the Dartmouth summer research project on artificial intelligence.** 31 ago. 1955. Disponível em: <http://jmc.stanford.edu/articles/dartmouth/dartmouth.pdf>. Acesso em: [confirmar data de acesso].

MOUSCHOUTZI, Maria. **RAG Explained: Understanding Embeddings, Similarity and Retrieval. Towards Data Science**, [s. l.], 17 set. 2025. Disponível em: <https://towardsdatascience.com/rag-explained-understanding-embeddings-similarity-and-retrieval/>. Acesso em: 16 mar. 2026.

SHANNON, Claude E. **A symbolic analysis of relay and switching circuits.** 1937. 81 f. Thesis (Master of Science in Electrical Engineering) – Massachusetts Institute of Technology, Cambridge, 1937.

SHANNON, Claude E. **A mathematical theory of communication.** The Bell System Technical Journal, [S. l.], v. 27, n. 3, p. 379-423, jul. 1948; n. 4, p. 623-656, out. 1948.

SILVA, Denis Ribeiro da; COSTA, Daniel Fonseca da; PIMENTA, Alexandre. **A influência da Inteligência Artificial na Contabilidade e na Tributação das Organizações: uma revisão de literatura.** In: USP INTERNATIONAL CONFERENCE IN ACCOUNTING, 2022, São Paulo.

SOBREIRA, Victor. **Um panorama da história da Inteligência Artificial e suas aplicações na pesquisa histórica.** Varia Historia, Belo Horizonte, v. 41, e25035, 2025. DOI: <http://dx.doi.org/10.1590/0104-87752025v41e25035>.

TURING, Alan M. **Computing Machinery and Intelligence.** Mind, New York, v. 59, n. 236, p. 433-460, out. 1950.

PONTES, V. R. **tcc-ufsc-contabilidade-rag:** código-fonte do protótipo Sispetro AI. Florianópolis: GitHub, 2026. Disponível em: <https://github.com/vanrpontes/tcc-ufsc-contabilidade-rag>. Acesso em: 21 jun. 2026.

XIMENES DE MELO, S. A. B. et al. **Inteligência Artificial na Contabilidade: Uma Análise Bibliométrica.** Revista Aracê, São José dos Pinhais, v. 11, n. 1, p. 119-141, 2024.

APÊNDICE A – SÍNTESE DAS 24 PERGUNTAS-TESTE, CLASSIFICAÇÃO E NOTAS DE AVALIAÇÃO

ID	TIPO	PERGUNTA	PRECISÃO	RELEVÂNCIA	CLAREZA COERENCIA	APLICAÇÃO
1	Direta	Quais áreas precisam aprovar um Pedido de Venda antes do faturamento?	5	5	5	4
2	Direta	Como cancelar uma Nota Fiscal Eletrônica no Sispetro?	2	2	4	1
3	Direta	Como fazer o ajuste de estoque inicial por depósito?	4	5	5	5
4	Direta	Como acertar o saldo inicial das contas de banco?	5	5	5	4
5	Direta	O que é o Adiantamento Quantificado de Fornecedores?	4	5	5	4
6	Direta	Quais são os passos para liberar uma Ordem de Fabricação?	5	5	5	4
7	Direta	Como habilitar um relatório para geração em arquivo no Gerenciador de Relatórios?	5	5	5	5
8	Direta	Onde configuro o Vale Pedágio no sistema?	2	2	3	1
9	Direta	Como faço a importação de um arquivo XML no Sispetro?	4	5	4	4
10	Síntese	Qual é o fluxo completo desde a emissão do Pedido de Venda até o faturamento de combustíveis, passando pela Ordem de Carregamento?	4	5	4	3
11	Síntese	Quais cuidados devo ter ao lançar uma nota fiscal de entrada e depois reprocessá-la para os Livros Fiscais?	3	3	4	3
12	Síntese	Como funciona o processo de cobrança eletrônica, desde a configuração até a baixa de um título?	3	3	4	2
13	Síntese	Qual a diferença entre o Adiantamento a Fornecedores comum e o cenário em que o fornecedor do PMM difere do fornecedor da NF?	4	5	4	4
14	Síntese	Como o sistema trata o acerto automático quando o estoque chega a zero, e isso afeta as movimentações anteriores?	4	4	3	3
15	Síntese	Como funciona o rateio de custos de produção em conjunto com a Ordem de Fabricação?	5	5	4	4
16	Síntese	Como o módulo de Controladoria se relaciona com a manutenção de tabelas e o controle de acesso?	3	3	3	2
17	Síntese	Quais são as etapas para gerar e validar o arquivo DAC, incluindo a inclusão da DAC-AL?	4	4	3	3
18	Síntese	Como funciona a alteração de preços em um Pedido de Venda já existente e quais aprovações ela exige?	3	3	4	2
19	Direta	Como configuro a integração do Sispetro com o WhatsApp Business para notificar clientes?	4	3	4	3
20	Armadilha	O Sispetro possui módulo nativo de folha de pagamento com cálculo de INSS e FGTS?	5	5	5	5
21	Armadilha	Como faço para integrar o Sispetro com o ChatGPT para gerar relatórios automáticos?	1	2	3	1
22	Direta	Qual é o procedimento para emitir Nota Fiscal de Serviço (NFS-e) no Sispetro?	4	4	4	3
23	Armadilha	Como configuro a autenticação em dois fatores (2FA) para login de usuários no sistema?	1	2	3	1
24	Armadilha	O Sispetro tem aplicativo mobile nativo para Android e iOS?	1	2	3	1

Nota: Por questões de espaço e legibilidade, esta tabela apresenta uma síntese dos resultados da validação. O conjunto completo do instrumento — incluindo as respostas literais geradas pelo protótipo, os trechos correspondentes do manual técnico utilizados na checagem documental, a nota de usabilidade (avaliação única do protótipo, conforme seção 4.3) e as observações qualitativas registradas para cada pergunta — está disponível na planilha eletrônica instrumento_validacao_sispetro.xlsx, publicada no repositório do projeto: https://github.com/vanrpontes/tcc-ufsc-contabilidade-rag/blob/main/docs/instrumento_validacao_sispetro.xlsx (PONTES, 2026).